

Training di Kaggle dan Rekonstruksi Citra Fashion-MNIST melalui Decoder


Nama: Amira Fathinah / 452024618075

Teknik Informatika / Semester 5

A. PENJELASAN SINGKAT ARSITEKTUR AUTOENCODER

Autoencoder merupakan model *neural network* yang digunakan untuk mempelajari representasi data secara tidak terawasi (*unsupervised learning*). Pada tugas ini, autoencoder digunakan untuk merekonstruksi citra Fashion-MNIST. Arsitektur autoencoder terdiri dari dua bagian utama yaitu encoder dan decoder. Encoder berfungsi mengubah citra input menjadi representasi berdimensi lebih kecil yang disebut latent vector atau latent space. Selanjutnya, decoder menggunakan latent vector tersebut untuk membangun kembali citra sehingga menghasilkan reconstructed image yang menyerupai citra asli.

Alur kerja autoencoder pada tugas ini terlampir pada gambar dibawah ini. Proses ini memungkinkan model mempelajari informasi penting dari citra dan mengompresinya ke dalam ruang representasi yang lebih ringkas.




B. PENJELASAN PROSES TRAINING DI KAGGLE

Proses training dilakukan menggunakan Kaggle Notebook dengan dataset Fashion-MNIST. Dataset ini berisi citra pakaian grayscale berukuran 28×28 piksel. Model autoencoder dilatih menggunakan fungsi loss Mean Squared Error (MSELoss) dan optimizer Adam. Training dilakukan selama 10 epoch hingga nilai loss menunjukkan tren menurun.




Eksperimen ini dilakukan menggunakan tiga ukuran latent dimension yaitu 2, 8, dan 32. Setiap model dilatih secara terpisah untuk melihat pengaruh ukuran latent space terhadap kualitas rekonstruksi citra.

Latent Dimension 2	Latent Dimension 8	Latent Dimension 32
Epoch [1/10] - Loss: 0.045788 Epoch [2/10] - Loss: 0.033052 Epoch [3/10] - Loss: 0.031831 Epoch [4/10] - Loss: 0.031218 Epoch [5/10] - Loss: 0.030789 Epoch [6/10] - Loss: 0.030447 Epoch [7/10] - Loss: 0.030131 Epoch [8/10] - Loss: 0.029856 Epoch [9/10] - Loss: 0.029639 Epoch [10/10] - Loss: 0.029433	Epoch [1/10] - Loss: 0.037246 Epoch [2/10] - Loss: 0.020808 Epoch [3/10] - Loss: 0.018803 Epoch [4/10] - Loss: 0.017925 Epoch [5/10] - Loss: 0.017380 Epoch [6/10] - Loss: 0.016990 Epoch [7/10] - Loss: 0.016704 Epoch [8/10] - Loss: 0.016482 Epoch [9/10] - Loss: 0.016296 Epoch [10/10] - Loss: 0.016132	Epoch [1/10] - Loss: 0.035958 Epoch [2/10] - Loss: 0.019218 Epoch [3/10] - Loss: 0.016518 Epoch [4/10] - Loss: 0.015029 Epoch [5/10] - Loss: 0.014006 Epoch [6/10] - Loss: 0.013214 Epoch [7/10] - Loss: 0.012611 Epoch [8/10] - Loss: 0.012124 Epoch [9/10] - Loss: 0.011746 Epoch [10/10] - Loss: 0.011415

C. HASIL GRAFIK LOSS



D. HASIL REKONSTRUKSI DARI BEBERAPA UKURAN LATENT DIMENSION

Latent Dimension 2	Latent Dimension 8	Latent Dimension 32
		
Hasil rekonstruksi masih mampu mempertahankan bentuk umum objek, namun beberapa detail visual terlihat berkurang akibat ukuran latent space yang sangat kecil.	Kualitas rekonstruksi lebih baik dibandingkan latent dimension 2. Bentuk objek lebih jelas dan detail citra lebih terjaga.	Hasil rekonstruksi paling mendekati citra asli. Sebagian besar detail visual dapat dipertahankan dengan baik karena latent space memiliki kapasitas representasi yang lebih besar.

E. PENJELASAN CARA MENJALANKAN PROGRAM DARI TERMINAL




Setelah model selesai dilatih dan disimpan dalam format .pth, proses rekonstruksi dilakukan melalui terminal menggunakan file reconstruct.py. Program membaca model hasil training, memuat kembali arsitektur autoencoder, memilih data Fashion-MNIST berdasarkan indeks tertentu, melakukan rekonstruksi citra, dan menyimpan hasilnya dalam bentuk file gambar. Berikut perintah yang digunakan untuk menjalankan program dari terminal:

```
python reconstruct.py --model autoencoder_fashion_mnist_latent2.pth --latent_dim 2 --index 10
```

```
python reconstruct.py --model autoencoder_fashion_mnist_latent8.pth --latent_dim 8 --index 10
```

```
python reconstruct.py --model autoencoder_fashion_mnist_latent32.pth --latent_dim 32 --index 10
```

F. SCREENSHOT TERMINAL

Latent Dimension 2	
Latent Dimension 8	
Latent Dimension 32	

G. ANALISIS HASIL

Berdasarkan hasil eksperimen yang telah dilakukan, autoencoder berhasil mempelajari representasi data Fashion-MNIST dan menghasilkan citra rekonstruksi yang menyerupai citra asli. Hal ini ditunjukkan oleh nilai loss yang terus mengalami penurunan selama proses training pada seluruh variasi latent dimension. Penurunan loss menunjukkan bahwa model semakin mampu meminimalkan perbedaan antara citra asli dengan citra hasil rekonstruksi sehingga proses pembelajaran berjalan dengan baik.

Pada arsitektur autoencoder, encoder berperan sebagai bagian yang mengubah citra input menjadi representasi berdimensi lebih kecil yang disebut latent vector atau latent space. Proses encoding tidak sekadar mengecilkan ukuran data, tetapi juga mengekstraksi karakteristik penting dari citra, seperti bentuk, pola, dan struktur objek. Informasi yang dianggap kurang penting akan dikurangi sehingga hanya fitur-fitur utama yang dipertahankan. Representasi tersebut kemudian disimpan dalam latent space yang berfungsi sebagai ruang representasi fitur hasil pembelajaran model.

Penyimpanan informasi dalam bentuk latent vector memiliki tujuan untuk menghasilkan representasi data yang lebih ringkas namun tetap mempertahankan informasi penting. Dengan cara ini, ukuran data dapat dikompresi tanpa harus menyimpan seluruh piksel citra asli. Selain menghemat dimensi data, latent vector juga memudahkan model dalam mempelajari pola yang bersifat umum sehingga proses rekonstruksi dapat dilakukan secara lebih efisien. Seluruh informasi yang dibutuhkan untuk membangun kembali citra disimpan dalam representasi laten tersebut.

Decoder kemudian menggunakan latent vector sebagai input utama untuk menghasilkan kembali citra hasil rekonstruksi. Decoder tidak dapat bekerja tanpa adanya latent vector karena representasi tersebut merupakan satu-satunya informasi yang diterima setelah proses encoding. Berdasarkan representasi fitur yang tersimpan pada latent space, decoder secara bertahap membangun kembali pola-pola visual hingga menghasilkan citra yang menyerupai gambar asli. Oleh karena itu, kualitas informasi yang tersimpan pada latent vector sangat menentukan kualitas hasil rekonstruksi yang dihasilkan oleh decoder.

Hasil eksperimen menunjukkan bahwa ukuran latent dimension memberikan pengaruh yang signifikan terhadap kualitas rekonstruksi citra. Pada latent dimension sebesar 2, proses kompresi berlangsung sangat tinggi sehingga kapasitas penyimpanan informasi menjadi sangat terbatas. Akibatnya, hasil rekonstruksi masih mampu mempertahankan bentuk umum objek, namun beberapa detail visual, seperti tekstur dan garis-garis halus, tidak dapat dipertahankan dengan baik. Hal tersebut menunjukkan bahwa ukuran latent space yang terlalu kecil menyebabkan hilangnya sebagian informasi penting selama proses encoding.

Ketika ukuran latent dimension ditingkatkan menjadi 8, kapasitas penyimpanan informasi menjadi lebih besar sehingga decoder memperoleh representasi fitur yang lebih lengkap. Hasil rekonstruksi pada konfigurasi ini terlihat lebih jelas dibandingkan latent dimension 2 karena lebih banyak detail visual yang berhasil dipertahankan. Selanjutnya, pada latent dimension sebesar 32, kualitas rekonstruksi menjadi yang terbaik di antara seluruh eksperimen. Citra hasil rekonstruksi terlihat paling mendekati citra asli karena model memiliki ruang representasi yang lebih luas untuk menyimpan informasi penting selama proses encoding. Dengan demikian, semakin besar latent dimension yang digunakan, semakin besar pula kemampuan model dalam mempertahankan informasi visual yang diperlukan untuk proses rekonstruksi.

Perbandingan nilai loss juga memperkuat hasil pengamatan secara visual. Pada latent dimension 2 diperoleh nilai loss akhir sebesar **0.029433**, kemudian menurun menjadi **0.016132** pada latent dimension 8, dan mencapai nilai terendah yaitu **0.011415** pada latent dimension 32. Nilai loss yang semakin kecil menunjukkan bahwa kesalahan rekonstruksi semakin rendah sehingga citra hasil rekonstruksi menjadi semakin mirip dengan citra asli. Dengan demikian, hasil numerik yang diperoleh konsisten dengan kualitas visual yang diamati pada ketiga hasil rekonstruksi.

Proses rekonstruksi yang dijalankan melalui notebook maupun melalui terminal pada dasarnya menghasilkan keluaran yang sama karena keduanya menggunakan bobot model yang identik. Perbedaannya terletak pada cara menjalankannya. Pada notebook, proses training dan inferensi dilakukan secara interaktif dalam satu lingkungan kerja, sedangkan pada terminal proses inferensi dilakukan dengan memuat kembali model yang telah disimpan dalam format .pth menggunakan file reconstruct.py. Keberhasilan rekonstruksi melalui terminal membuktikan bahwa model hasil training dapat digunakan kembali tanpa harus melakukan proses pelatihan ulang.

Agar proses inferensi berjalan dengan benar, arsitektur model yang digunakan saat memuat file .pth harus sama dengan arsitektur yang digunakan selama proses training. Perbedaan jumlah layer, ukuran latent dimension, maupun konfigurasi jaringan akan menyebabkan ketidaksesuaian bentuk parameter sehingga bobot model tidak dapat dimuat dengan benar. Oleh karena itu, kesesuaian arsitektur merupakan syarat penting dalam penggunaan kembali model hasil training.

Apabila decoder diberikan latent vector secara acak yang tidak berasal dari encoder, maka citra yang dihasilkan umumnya tidak menyerupai objek Fashion-MNIST yang sebenarnya. Hal ini disebabkan karena decoder hanya mempelajari distribusi latent vector yang dihasilkan oleh encoder selama proses training. Latent vector acak berada di luar distribusi yang dipelajari model sehingga informasi yang diberikan tidak cukup untuk menghasilkan rekonstruksi yang bermakna. Hasilnya biasanya berupa pola-pola acak atau citra yang tidak dapat dikenali dengan jelas.

Secara keseluruhan, hasil eksperimen menunjukkan bahwa autoencoder tidak sekadar menghafal atau menyalin kembali citra input, melainkan mempelajari representasi fitur penting dari data melalui proses encoding. Bukti dari hal tersebut terlihat dari kemampuan model menghasilkan rekonstruksi yang tetap menyerupai citra asli meskipun informasi telah dikompresi ke dalam latent space berdimensi jauh lebih kecil. Selain itu, adanya perbedaan kualitas rekonstruksi pada setiap ukuran latent dimension menunjukkan bahwa model benar-benar memanfaatkan representasi fitur yang dipelajari untuk membangun kembali citra, bukan sekadar melakukan penyalinan langsung terhadap data masukan.

H. TABEL PERBANDINGAN HASIL

Latent Dimension	Loss Akhir	Kualitas Visual	Catatan
2	0.029433	Cukup Baik	Bentuk objek masih dapat dikenali, namun beberapa detail visual hilang akibat kompresi yang tinggi.
8	0.016132	Baik	Detail citra lebih terjaga dibandingkan latent dimension 2 dan hasil rekonstruksi terlihat lebih jelas.
32	0.011415	Sangat Baik	Menghasilkan rekonstruksi yang paling mendekati citra asli dengan detail visual yang lebih lengkap.

I. KESIMPULAN

Berdasarkan hasil implementasi dan eksperimen yang telah dilakukan, autoencoder berhasil dilatih menggunakan dataset Fashion-MNIST dan mampu melakukan rekonstruksi citra dengan baik. Proses training menunjukkan penurunan nilai loss pada setiap epoch yang menandakan bahwa model berhasil mempelajari pola data dan meningkatkan kualitas rekonstruksi secara bertahap.

Hasil pengujian menunjukkan bahwa ukuran latent dimension memiliki pengaruh terhadap kualitas citra hasil rekonstruksi. Latent dimension yang lebih kecil menghasilkan tingkat kompresi yang lebih tinggi, namun menyebabkan berkurangnya detail visual pada citra. Sebaliknya, latent dimension yang lebih besar mampu mempertahankan lebih banyak informasi sehingga menghasilkan rekonstruksi yang lebih mendekati citra asli.

Selain itu, model yang telah disimpan dalam format .pth berhasil dimuat kembali melalui program reconstruct.py dan digunakan untuk melakukan rekonstruksi citra tanpa perlu melakukan training ulang. Dengan demikian, seluruh tahapan yang diminta dalam tugas, mulai dari training di Kaggle, penyimpanan model, hingga inferensi melalui terminal, telah berhasil diimplementasikan dengan baik.